



FH Salzburg
MultiMediaTechnology

***Einführung in die Multiple Imputation im
Medizinischen Bereich: Wann sie geeignet ist und
wie optimale Ergebnisse erzielt werden können***

Seminararbeit

AutorIn: Christoph Marko

BetreuerIn: DI Dr. Simon Ginzinger

Repository: <https://gitlab.mediacube.at/fhs1111/seminararbeit>

Salzburg, Österreich, 21.06.2021

Einführung in die Multiple Imputation im Medizinischen Bereich: Wann sie geeignet ist und wie optimale Ergebnisse erzielt werden können

Christoph Marko

cmarko.mmt-b2019@fh-salzburg.ac.at

FH Salzburg

1 EINLEITUNG

In der Medizinischen Forschung ist es wichtig, dass Studienergebnisse mit fehlenden Daten sorgfältig analysiert und bearbeitet werden. Das soll verhindern, dass es zu einer Verzerrung des Ergebnisses kommt. Viele Medizinische Zeitschriften verlangen bereits einen korrekten Umgang mit fehlenden Daten sowie eine Rechtfertigung für den gewählten statistischen Ansatz. (Lee und Simpson 2014, 163) Eine wichtige Methode zur Behandlung von fehlenden Daten ist die Multiple Imputation (MI).

Die Multiple Imputation (MI) ist ein statistisches Verfahren, in welchem fehlende Daten anhand einer Wahrscheinlichkeitsverteilung mehrfach ersetzt und gemittelt werden. (Lee und Simpson 2014, 163)

Ziel dieser Arbeit ist es, einen Überblick über die MI im Medizinischen Bereich zu geben. Neben einer Erklärung der MI, wird auf wichtige Fragestellungen bei der Durchführung der MI eingegangen.

Ein wichtiger Teil bei der Durchführung der MI ist die Planung der MI und die Überprüfung des Datensatzes. Dabei wird im Forschungsblatt der Anteil von fehlenden Daten sowie die Art der fehlenden Daten erläutert. Des Weiteren muss die Methode der Imputation gewählt werden. Es werden einige Alternativen zur MI aufgezeigt und es wird auf den Vorteil von Hilfsvariablen bzw. Post-Baseline Untersuchungen eingegangen. Nach der Durchführung der Imputation kann die Sensitivität/Qualität ermittelt werden. Hierbei werden im Forschungsblatt unterschiedliche Mittel zur Qualitätsfeststellung beschrieben.

2 MULTIPLE IMPUTATION

2.1 Anwendungsbeispiel der MI

Angenommen es würde eine Studie über den Zusammenhang zwischen Blutdruck und dem Risiko eines Herzinfarkts geben. Dabei fehlen die Blutdruck Daten bei einigen Herzinfarkt-Patienten. Man kann nun aufgrund der anderen Daten die gesammelt wurden Rückschluss auf die fehlenden Daten ziehen. So können z.B. die fehlenden Blutdruck-Daten einiger Patienten ersetzt werden, indem andere Patienten mit gleichen Eigenschaften gesucht werden. Bei Patienten mit gleichen Eigenschaften (z.B. gleiches Alter, gleicher BMI) steigt auch die Wahrscheinlichkeit, dass der Puls-Wert ähnlich ist.

Allerdings kann diese Vorgehensweise aufwändig werden. Vor allem, wenn es sehr viele Variablen gibt. Es wird z.B.

schwierig werden, einen Patienten mit genau dem selben BMI, Alter, Blutdruck, Geschlecht etc. zu finden. Daher wird in der MI versucht, anhand der vorhandenen Daten und einer Verteilungsfunktion eine Vermutung über den fehlenden Wert zu bekommen. Man könnte z.B. davon ausgehen, dass die Pulswerte der Bevölkerung Normalverteilt sind. Aufgrund dieser Vermutung kann der Mittelwert aller Pulswerte gebildet und für die fehlenden Daten eingesetzt werden. Für Komplexere Sachverhalte ist dieses Vorgehen allerdings nicht ausreichend. (Donders u. a. 2006, 1089)

Um den gesamten Sachverhalt besser darstellen zu können, werden z.B. mehrere voneinander abhängige Regressionsmodelle (Conditional Regression Models) oder eine Mehrdimensionale Normalverteilung (Joint Normal Distribution) benötigt. Damit werden mehrere Eigenschaften/Variablen berücksichtigt. (Lee und Simpson 2014, 164). Aus so einem Modell werden die Werte nun nicht nur einmal, sondern mehrfach imputiert. Für die Studie könnte z.B. ein Conditional Regression Modell erstellt werden, dass das Risiko eines Herzinfarktes bezogen auf Alter, Blutdruck, BMI, etc. darstellt. Werden nun aus diesem Regressions Modell mehrfach Schätzwerte gezogen und diese Schätzwerte dann kombiniert, handelt es sich um eine MI.

2.2 Funktionsweise der MI

Ausgangspunkt der MI ist das Analysis Modell. Das Analysis Modell ist ein Datensatz, in welchem Daten verschiedener Variablen fehlen können. In der ersten Phase der MI wird aus dem Analysis Modell ein Imputation Modell erstellt. Dazu werden dem Analysis Model noch zusätzliche Variablen, sogenannte auxiliary variables (Hilfsvariablen) hinzugefügt. Die fehlenden Daten werden darauf hin z.B. mit Hilfe eines Regressionmodells mehrfach imputiert. Durch die mehrfache Imputation entstehen mehrere Vervollständigte Datensätze. In der zweiten Phase werden die Vervollständigten Datensätze analysiert und gemittelt, wodurch der finale Datensatz ermittelt wird. Durch die Berechnung des Standard Errors kann die Unsicherheit der Daten ermittelt werden. (Lee und Simpson 2014, 163) Im Folgenden wird auf die beiden Phasen der MI näher eingegangen.

2.3 Phase 1: Mehrfache Imputation

Die Grundsätzliche Idee der MI ist es, ein Regressionsmodell zu erstellen, dass mögliche Werte für die zu ersetzenden Werte beinhaltet. Aus diesem Regressionmodell werden in Folge

anhand einer Simulation randomisiert Werte gezogen. Angenommen, es würde sich um eine Normalverteilung handeln, dann würden die fehlenden Daten vereinfacht über folgende Formel aus Enders (2017, 8) gezogen werden:

$$Y_{(mis)} \sim N(\hat{Y}, \sigma_{\varepsilon}^2) \quad (1)$$

„ $Y_{(mis)}$ ist ein Schätzwert für den fehlenden Wert. $\sim N$ bezeichnet die Normalverteilung, \hat{Y} ist der vorhergesagte Wert aus einer Regressionsgleichung und σ_{ε}^2 ist die Residuenvarianz aus der Regression.“ (Enders 2017, 8) Die Varianz definiert den Mittelwert sowie die Streuung. Insgesamt ist die Imputation aus einer Gleichung die Summe eines Abweichungswertes (Varianz) und des vorhergesagten Wertes. (Enders 2017, 8) Um fehlende Daten in mehreren Variablen zu berücksichtigen werden komplexere Regressionsmodelle, wie das Conditional Regression Model oder die Joint Normal Distribution benötigt. Das Zufällige ziehen von Schätzungen zu den fehlenden Werten wird mehrfach wiederholt, wodurch mehrere Vollständige Datensätze entstehen, auf denen daraufhin die Analyse durchgeführt wird. (Lee und Simpson 2014, 163 ff.) Durch das Wiederholen der Imputationen mit unterschiedlichen, plausiblen Regressions-Parametern, gleichen die Datensätze keiner Imputation der anderen. Dadurch wird die Unsicherheit der Imputation adressiert. (Enders 2017, 8)

2.4 Phase 2: Analyse der Daten

In der 2. Phase wird jeder der Imputierten Datensätze getrennt betrachtet. Wenn z.B. 20 Imputationen durchgeführt wurden, gibt es 20 Datensätze, die Schätzwerte für die fehlenden Werte beinhalten. Für jeden dieser Datensätze wird ein gemeinsamer Schätzwert (z.B. über das Arithmetische Mittel) und der Standard Error berechnet. Zuletzt werden die 20 Datensätze noch kombiniert, indem das Arithmetische Mittel der Schätzwerte sowie des Standard Errors gebildet wird. (Enders 2017, 10)

2.5 Praktische Anwendung der MI

Statistische Programme wie SAS und Stata unterstützen bereits MI unter der Verwendung des Conditional Regression Modells sowie der Joint Normal Distribution. (Lee und Simpson 2014, 164). Da dieses Paper einen Allgemeinen Überblick über die MI geben soll, wird auf die genaue Implementation nicht mehr eingegangen.

Eine Implementation der MI kann in Royston (2005) gefunden werden. Dort wird die Implementierung der MI in der MICE Methode näher anhand von ado-Dateien erläutert. Ado-Dateien sind Dateien, welche vom Statistik Programm Stata verwendet werden.

2.6 Vorgehensweise MI

Bevor die MI durchgeführt werden kann. Sollten einige wichtige Punkte geklärt werden, die in den nächsten Kapiteln näher erläutert werden. So stellt sich unter anderem die Frage, wie groß der Anteil an fehlenden Daten ist und welche Auswirkungen dies hat. (Siehe Kapitel 3). Nach der Durchführung der MI sollte zu dem die Qualität der MI überprüft werden (siehe Kapitel 7).

3 ANTEIL AN FEHLENDEN DATEN

Es gibt in der Forschung unterschiedliche Empfehlungen, bis zu welchem Anteil an fehlenden Daten zuverlässige Ergebnisse erzielt werden können. Statistische Leitartikel gehen davon aus, dass es ab 10% an fehlenden Daten wahrscheinlich zu einem Bias kommen kann. Ab 40% sollte das Ergebnis der MI nur mehr als Hypothese gesehen werden. Die Beweislage, die diese Grenzen stützt, ist allerdings gering. (Madley-Dowd u. a. 2019, 63 f.)

In der Studie “The proportion of missing data should not be used to guide decisions on multiple imputation” wird argumentiert, dass der Anteil an fehlenden Daten nicht unbedingt ausschlaggebend für den Erfolg oder Misserfolg der MI steht. Viel mehr spielen die Art der fehlenden Daten und die Verwendung von auxiliary Variablen eine wichtige Rolle.

4 ART DER FEHLENDEN DATEN

Nach Definition von (Little & Rubin, 2002; Rubin, 1976) gibt es 3 verschiedene Arten von fehlenden Daten:

4.1 MCAR: Missing Completely at Random

Die Fehlenden Daten haben keine Verbindung zu den zu analysierenden Daten. Gründe für MCAR Daten können zum Beispiel ein Strom- oder Internetausfall sein. (Enders 2017, 8)

4.2 MAR: Missing at Random

Systematische Unterschiede zwischen den fehlenden Daten und den Untersuchten Daten können erklärt werden. So können zum Beispiel Blutdruckwerte v.a. bei jüngeren Personen fehlen, da bei diesen der Blutdruck weniger oft kontrolliert wird. (Sterne u. a. 2009, 157) An den vorhandenen Daten kann man nun erkennen, dass es bei Menschen mit Jüngerem Alter öfter zu fehlenden Blutdruckdaten kommt. Man könnte daher repräsentativ für die fehlenden Blutdruckdaten, die Blutdruckdaten anderer Junger Teilnehmer verwenden, bei welchen die Messung des Blutdrucks nicht vergessen wurde.

4.3 NMAR: Not Missing at Random

Es gibt systematische Unterschiede, welche nicht anhand der Untersuchten Daten erkannt werden können. NMAR Daten können zum Beispiel entstehen, wenn Patienten mit hohem Blutdruck häufiger aufgrund von Kopfschmerzen fehlen. (Sterne u. a. 2009, 157) Anhand der vorhandenen Daten kann man nun nicht erkennen, dass es eine Gruppe von Menschen mit Kopfschmerzen gibt, welche bei den Blutdruckmessungen fehlt.

NMAR-Daten können anhand von statistischen Tests nicht identifiziert werden. NMAR-Daten können also nur als solche durch vorhandenes Wissen interpretiert werden. Daher gibt es keine allgemein Gültige Methode für die Behandlung von NMAR-Daten. (Donders u. a. 2006, 1088)

4.4 Auswirkungen auf das Ergebnis der MI

MAR- und NMAR Daten sind schwer zu unterscheiden. NMAR können jedoch zu einem voreingenommenen Resultat führen. Um das Risiko eines voreingenommenen Ergeb-

nisses durch NMAR Daten zu verringern, kann eine Sensitivitätsanalyse angewendet werden. (Sterne u. a. 2009, 157)

Wenn es sich um MCAR Daten handelt, können anstatt der MI einfachere Methoden wie die Complete Case Analysis in Betracht gezogen werden. (2006, 1088)

5 ALTERNATIVEN ZUR MI

5.1 Complete Case Analysis (CCA)

Bei der CCA werden Teilnehmer mit fehlenden Daten aus der Studie exkludiert. (Jakobsen u. a. 2017, 3)

In einer Simulation aus Heijden u. a. (2006) erzielte die CCA schlechtere Ergebnisse als die MI. Für die Simulation wurden Daten aus einer Studie zu Lungenembolie mit 398 Subjekten verwendet. Dabei gab es einen Unterschiedlichen Anteil an fehlenden Daten bei einigen Variablen. Bei den fehlenden Daten handelte es sich nicht um MCAR Daten. Das Ergebnis der CCA schnitt dabei in allen Messgrößen im Vergleich zur single- und multiplen Imputation schlechter ab. Als Qualitätskriterien wurden u.a. der Standard Error sowie die Regressions Koeffizienten verwendet. Mögliche Qualitätskriterien werden in Kapitel XY nochmals näher erläutert.

Wenn es sich im Datensatz wie in der oben genannten Simulation nicht um MCAR-Daten handelt, dann ist das Ergebnis der CCA vermutlich voreingenommen. Grund dafür ist, dass die CCA systematische Unterschiede nicht berücksichtigt. (Sterne u. a. 2009, 157) Im Fall von MAR-Daten eignet sich daher die Single- oder Multiple Imputation besser. (Donders u. a. 2006, 1088)

5.2 Single Imputation

Bei der Single Imputation werden fehlende Daten nach einer Regel ersetzt. Von der Single Imputation gibt es mehrere Varianten. Bei der Last Observation Carried Forward (LOCF) werden fehlende Daten mit den Daten aus der letzten Untersuchung ersetzt. Bei der Worst Observation Carried Forward werden fehlende Daten mit dem schlechtesten untersuchten Ergebnis des Patienten ersetzt. Bei der Simple Mean Imputation wird der Mittelwert verwendet. Die Single Imputation hat die Annahme, dass fehlende Werte und in der Vergangenheit gemessene Werte identisch sind. Diese Annahme ist allerdings unrealistisch, weshalb diese Methode mit Bedacht eingesetzt werden soll. (Jakobsen u. a. 2017, 3)

Eine Simulation aus Young-Saver u. a. (2018) zeigt, dass mit der LOCF Methode ähnlich gute oder sogar bessere Ergebnisse erzielt werden können als mit der MI. In der Simulation wurden Daten aus einer Studie zu akutem Schlaganfall verwendet. Begründet wird das gute Abschneiden der LOCF u.a. mit der zeitlichen Nähe der letzten Untersuchung zu dem zu schätzen den Wert. Durch die zeitliche Nähe haben zeitrelevante Prozesse, wie Neuroplastizität oder Neuronale Regeneration (neuronale Prozesse) keinen so großen Einfluss. Zudem ist die Wahrscheinlichkeit von Vorfällen geringer, welche Einfluss auf die zu erhebenden Werte haben könnten. Dazu gehören z.B. Unfälle oder Herzinfarkte. (Young-Saver u. a. 2018, 3667). Wie gut die LOCF Methode im Vergleich zur MI abschneidet kann jedoch nicht allgemein gesagt werden und hängt maßgeblich von den verwendeten Daten ab.

5.3 Wann bietet sich der Einsatz von CCA oder Single Imputation an?

Die Anwendung der CCA bietet sich an, wenn es sich um MCAR-Daten handelt. Die Single Imputation sollte mit Bedacht eingesetzt werden. Sie kann jedoch unter Umständen ähnliche gute Ergebnisse wie die MI erzielen. Die LOCF Methode bietet sich vor allem an, wenn es relevante, zeitnahe Untersuchungen gibt und es sich bei den untersuchten Variablen um Zeitrelevante Prozesse handelt.

6 ZUSÄTZLICHE DATEN

6.1 Post-Baseline Untersuchungen

Die Simulation aus Young-Saver u. a. (2018) zum Thema akutem Schlaganfall, welche im Kapitel „Single Imputation“ bereits erwähnt wurde, zeigt auch die Bedeutung von Post-Baseline Untersuchungen. Post-Baseline Untersuchungen sind Untersuchungen, die nach einem Bestimmtem Ereignis erhoben wurden. Im Falle der Studie wurde der NIH Stroke Scale nach 24 Stunden und der mRS nach 7-10 Tagen erhoben. (der NIH Stroke Scale und der mRS sind beides Bewertungsskalen für die Symptome des Patienten). Die MI wurde einmal mit und einmal ohne Daten aus den Post-Baseline Untersuchungen durchgeführt. Im Ergebnis der Simulation schnitt die Multiple Imputation mit Post-Baseline besser ab als ohne (siehe Abbildung 1)

6.2 Hilfsvariablen

Unter Hilfsvariablen (engl.: auxiliary variables) versteht man Variablen, welche dem Datensatz im Nachhinein hinzugefügt werden, um die Menge an Information zu erhöhen. Auxiliary Variablen können z.B. aus anderen Studien/Datensätzen herangezogen werden.

Eine Simulation in Madley-Dowd u. a. (2019) zeigt die Bedeutung der Auxiliary Variablen. Die Simulation wurde anhand von Daten aus ALSPAC (Avon Longitudinal Study of Parents and Children) durchgeführt.

7 QUALITÄTSFESTSTELLUNG MI

7.1 Bias

Ein Qualitätskriterium für die MI ist der Bias. Unter Bias versteht man einen systematischen Fehler. Dieser Fehler entsteht, wenn der Einfluss von Eigenschaften über- oder unterbewertet wird. (Jakobsen u. a. 2017, 2) Angenommen, der Blutdruck ist ein wichtiger Faktor bei der Entstehung von Herz-Kreislauferkrankungen. Sollte eine Studie den Blutdruck nicht als Faktor für die Entstehung von Herz-Kreislauferkrankungen miteinbeziehen, ist das Ergebnis vermutlich biased bzw. voreingenommen.

Eine ordnungsgemäße Durchführung der MI, sowie eine genaue Überprüfung des Datensatzes, ist noch keine Garantie dafür, dass das Ergebnis nicht biased ist. Vor allem wenn nicht klar ist, ob es sich bei den verwendeten Daten um MAR oder MNAR Daten handelt. Es gibt einige Möglichkeiten, um die Qualität der MI zu Überprüfen und damit auch eine Abschätzung über einen Möglichen bias zu geben. Im Folgenden werden diese

Missing Data Handling Method	Disability-Free (mRS 0-1) Actual p value with no missing data: 0.014					Reduced Disability (all 7 mRS ranks) Actual p value with no missing data: 0.035				
	5% Missing	10% Missing	15% Missing	20% Missing	25% Missing	5% Missing	10% Missing	15% Missing	20% Missing	25% Missing
No data used from cases with missing final outcome										
Complete Case Analysis	0.022	0.028	0.042	0.051	0.059	0.045	0.049	0.067	0.074	0.094
Worst Case Imputation	0.024	0.032	0.049	0.061	0.073	0.069	0.088	0.154	0.160	0.245
Baseline data only used from cases with missing final outcome										
Multiple Imputation – Baseline Variables Only	0.022	0.032	0.049	0.058	0.079	0.046	0.054	0.072	0.079	0.105
Post-baseline data used from cases with missing final outcome										
Last Observation Carried Forward	0.015	0.015	0.015	0.015	0.013	0.036	0.033	0.036	0.036	0.037
Multiple Imputation – Baseline + Post-Baseline Variables	0.017	0.018	0.020	0.021	0.022	0.036	0.035	0.037	0.039	0.043

Abbildung 1: Die MI mit Post-Baseline Variablen (orange umrahmt) schnitt bei jedem Prozentsatz an fehlenden Daten besser ab als die MI ohne Post Baseline Variablen (blau umrahmt). Berechnet wurde der P-Value. Je näher der P-Value an 1 liegt, desto höher ist die Wahrscheinlichkeit, dass die Ergebnisse Zufall sind. Ein niedriger P-Value ist daher anzustreben. Grafik aus Young-Saver u. a. (2018, 3667), die Beschriftung sowie die blaue/orange Markierung wurde nachträglich hinzugefügt.

7.2 Standard Error und P-Value

Standardmäßig wird in der MI der Standard Error berechnet. Der Standarderror ist ein Maß für die Unsicherheit der geschätzten Werte. (Donders u. a. 2006, 1098)

Des Weiteren kann der P-Wert berechnet werden. Der P-Wert ist ein Wert zwischen 0 und 1. Je höher der P-Wert ist, desto höher ist die Wahrscheinlichkeit, dass die Ergebnisse Zufall sind. Ein niedriger P-Wert ist in der MI daher anzustreben.

7.3 Simulierte fehlende Daten

Eine einfache Methode zur Qualitätsüberprüfung ist es, einen vollständigen Datensatz zu nehmen und die fehlenden Daten zu simulieren. Nach dieser Vorgehensweise wurde auch die Simulation aus (D. Young-Saver, 2018) durchgeführt. Hierbei wurde aus dem Vollständigen Datensatz auf Basis eines randomisierten Verfahrens Daten gelöscht. Daraus folgt, dass man nun die imputierten Daten mit den Daten des Vollständigen Datensatzes vergleichen kann. Ein möglicher Vergleich wäre z.B. die Bestimmung der exakten Übereinstimmungsrate. Hierbei wird der Anteil von exakten Übereinstimmungen zwischen den imputierten und originalen Werten bestimmt. Des Weiteren kann Spearmans Korrelationskoeffizient, oder die Mittlere (Absolute) Abweichung bestimmt werden. (Young-Saver u. a. 2018, 3664)

7.4 Sensitivitätsanalyse

Vor der Durchführung der MI sollte eine Vermutung über die Art der fehlenden Daten gemacht werden. Sind die Daten MAR, MNAR oder MCAR? Angenommen es gibt eine Studie, die den Zusammenhang zwischen Blutdruck und Herz-Kreislauferkrankungen untersucht. Sollte ein Teil der Patienten diese Studie vorzeitig verlassen, könnte man vermuten, dass dies komplett zufällig geschieht. Die Daten wären somit MCAR. Es könnte aber auch sein, dass einige Patienten die

Studie aufgrund von Kopfschmerzen wegen zu hohen Blutdrucks verlassen. Damit gäbe es einen systematischen Zusammenhang und die Daten wären MAR oder MNAR. In vielen Studien ist es schwer, eine sichere Vermutung über die Art der fehlenden Daten zu treffen. Mit Sensitivitätsanalysen können mehrere Vermutungen über die Art der fehlenden Daten überprüft werden. (Cro u. a. 2020, 2815) (Cro, Suzie, 2020)

Im Allgemeinen gibt es 2 Varianten der Sensitivitätsanalyse: δ -basiert und referenzbasiert. In der δ -basierten Variante wird dem zu Erwarteten Wert noch ein Offset Variable δ (Delta) hinzugefügt, welche den Einfluss von fehlenden/nicht-beobachteten Teilnehmern bewertet. In der Referenzbasierten Sensitivitätsanalyse werden Werte aus anderen Gruppen des Versuchs imputiert, welche Referenz zu den Beobachteten Werten beinhaltet. (Cro u. a. 2020, 2815) Eine praktische Beschreibung der Durchführung der Sensitivitätsanalyse in Verbindung mit der MI kann in Cro u. a. (2020) gefunden werden.

8 FAZIT

Eine sorgfältige Planung und Durchführung der Imputation ist wichtig, damit es nicht zu verzerrten Ergebnissen kommt. Im ersten Schritt sollte der verwendete Datensatz überprüft werden. Bei den Verwendeten Daten sollte der Anteil an fehlenden Daten nicht zu hoch sein. In der Forschung gibt es jedoch unterschiedliche Vorgaben, welche Menge an fehlenden Daten in Ordnung ist. Mehr Forschung wäre hier von Vorteil. Bei der Art der fehlenden Daten sollte es sich möglichst um MAR Daten handeln.

Im Zweiten Schritt sollte die zu verwendende Imputations-Methode, sowie die Verwendung von zusätzlichen Variablen geplant werden. Handelt es sich um MCAR Daten, kann der Einsatz einer CCA überlegt werden. Gibt es relevante, zeitnahe Untersuchungen zu den fehlenden Daten, kann auch die Verwendung der Single Imputation in der LOCF-Variante gu-

te Ergebnisse erzielen. Das Hinzufügen von Post-Baseline Untersuchungen oder Auxilliary Variablen kann das Resultat der MI verbessern.

Nach der Durchführung der MI ist es zu empfehlen, eine Sensitivitätsanalyse durchzuführen. Vor allem, wenn es sich nicht sicher um MAR Daten handelt. Der Standard Error sowie der P-Value sollten nicht zu hoch sein, da hohe Werte auf ein biased Ergebnis hinweisen könnten.

MI ist eines der wichtigsten Werkzeuge für die Behandlung von fehlenden Daten in vielen verschiedenen Bereichen. Wer sich z.B. mit Statistik oder AI beschäftigt, sollte einen Überblick über MI haben. MI ist ein komplexes Thema und auch dieses Forschungsblatt konnte nur einen kleinen Überblick zum Thema MI geben. Es ist daher von Vorteil, dass die meisten Statistischen Programme bereits MI unterstützen und so den Einstieg in die MI vereinfachen.

LITERATURVERZEICHNIS

- Cro, Suzie, Tim P. Morris, Michael G. Kenward und James R. Carpenter. 2020. »Sensitivity analysis for clinical trials with missing continuous outcome data using controlled multiple imputation: A practical guide«. *Statistics in Medicine* 39 (21): 2815–2842. ISSN: 10970258. <https://doi.org/10.1002/sim.8569>.
- Donders, A. Rogier T., Geert J.M.G. van der Heijden, Theo Stijnen und Karel G.M. Moons. 2006. »Review: A gentle introduction to imputation of missing values«. *Journal of Clinical Epidemiology* 59 (10): 1087–1091. ISSN: 08954356. <https://doi.org/10.1016/j.jclinepi.2006.01.014>.
- Enders, Craig K. 2017. »Multiple imputation as a flexible tool for missing data handling in clinical research«. *Behaviour Research and Therapy* 98:4–18. ISSN: 1873622X. <https://doi.org/10.1016/j.brat.2016.11.008>. <http://dx.doi.org/10.1016/j.brat.2016.11.008>.
- Heijden, Geert J.M.G. van der, A. Rogier T. Donders, Theo Stijnen und Karel G.M. Moons. 2006. »Imputation of missing values is superior to complete case analysis and the missing-indicator method in multivariable diagnostic research: A clinical example«. *Journal of Clinical Epidemiology* 59 (10): 1102–1109. ISSN: 08954356. <https://doi.org/10.1016/j.jclinepi.2006.01.015>.
- Jakobsen, Janus Christian, Christian Gluud, Jørn Wetterslev und Per Winkel. 2017. »When and how should multiple imputation be used for handling missing data in randomised clinical trials - A practical guide with flowcharts«. *BMC Medical Research Methodology* 17 (1): 1–10. ISSN: 14712288. <https://doi.org/10.1186/s12874-017-0442-1>.
- Lee, Katherine J., und Julie A. Simpson. 2014. »Introduction to multiple imputation for dealing with missing data«. *Respirology* 19 (2): 162–167. ISSN: 13237799. <https://doi.org/10.1111/resp.12226>.

Madley-Dowd, Paul, Rachael Hughes, Kate Tilling und Jon Heron. 2019. »The proportion of missing data should not be used to guide decisions on multiple imputation«. *Journal of Clinical Epidemiology* 110:63–73. ISSN: 18785921. <https://doi.org/10.1016/j.jclinepi.2019.02.016>. <https://doi.org/10.1016/j.jclinepi.2019.02.016>.

Royston, Patrick. 2005. »Multiple imputation of missing values: Update of ice«. *Stata Journal* 5 (4): 527–536. ISSN: 1536867X. <https://doi.org/10.1177/1536867X0500500404>.

Sterne, Jonathan A.C., Ian R. White, John B. Carlin, Michael Spratt, Patrick Royston, Michael G. Kenward, Angela M. Wood und James R. Carpenter. 2009. »Multiple imputation for missing data in epidemiological and clinical research: Potential and pitfalls«. *BMJ (Online)* 339 (7713): 157–160. ISSN: 17561833. <https://doi.org/10.1136/bmj.b2393>.

Young-Saver, Dashiell F., Jeffrey Gornbein, Sidney Starkman und Jeffrey L. Saver. 2018. »Handling of Missing Outcome Data in Acute Stroke Trials: Advantages of Multiple Imputation Using Baseline and Postbaseline Variables«. *Journal of Stroke and Cerebrovascular Diseases* 27 (12): 3662–3669. ISSN: 15328511. <https://doi.org/10.1016/j.jstrokecerebrovasdis.2018.08.040>. <https://doi.org/10.1016/j.jstrokecerebrovasdis.2018.08.040>.

Diese Arbeit hat folgende Länge (gezählt mit texcount):